

Физически обоснованная слепая деконволюция: Адаптивное извлечение секвенограмм через дифференцируемый рендеринг и калибровочную изотропную оптимизацию

Ваше Имя*

Кафедра вычислительной обработки сигналов

18 апреля 2026 г.

Аннотация

Акустический мониторинг в сложных средах сталкивается с фундаментальной проблемой перекрывающихся сигналов и многолучевой реверберации. В данной работе представлен новый метод слепого разделения сигналов (Blind Source Separation), извлекающий «секвенограммы» — точные, разреженные векторы временной активации — непосредственно из искаженных спектрограмм. В отличие от традиционной сверточной неотрицательной матричной факторизации (ConvNMF), мы отказываемся от пиксельных шаблонов в пользу дифференцируемого параметрического рендеринга, который архитектурно гарантирует соблюдение законов физики (например, точную привязку обертонов к основному тону). Для решения проблемы «курицы и яйца» при слепой оценке мы предлагаем метод совместной оптимизации сигналов, библиотеки шаблонов на сфере S^n и частотно-зависимого причинного фильтра эха. Устойчивость сложной многокомпонентной системы обеспечивается введением концепции Калибровочной нормировки (Gauge Calibration) и изотропной Евклидовой функции потерь, которая формирует динамическую тригонометрическую маршрутизацию градиентов, избавляя алгоритм от эвристического подбора гиперпараметров.

1 Введение

Распознавание акустических паттернов (например, эхолокационных криков летучих мышей) в естественных средах осложняется эффектами среды: затуханием и реверберацией. Традиционные методы деконволюции часто терпят неудачу, так как не могут отделить внутреннюю структуру сигнала от внешних искажений среды. Эта задача представляет собой классическую проблему совместной слепой оптимизации: невозможно точно оценить профиль эха без знания идеального шаблона сигнала, а извлечь шаблон невозможно без снятия реверберации.

В данной работе мы представляем физически обоснованную генеративную пайплайн-модель, которая решает эту проблему через совместную (joint) оптимизацию трех компонентов: разреженных векторов активации (*секвенограмм*), физически жестко связанной параметрической библиотеки шаблонов и частотно-зависимого 1D-фильтра эха.

2 Генеративная модель и Физический рендеринг

Пусть $S \in \mathbb{R}_{\geq 0}^{F \times T}$ — наблюдаемая спектрограмма. Генеративный процесс $\hat{S} = (H * W) * E$ моделируется следующим образом.

* Автор для корреспонденции: email@example.com

2.1 Параметрическая библиотека на сфере S^n и дифференцируемый рендеринг

Традиционные методы ConvNMF оптимизируют шаблоны $W \in \mathbb{R}^{F \times T_w}$ попиксельно, что приводит к размытию и нарушению структуры сигнала (например, независимости движения обертонов от основного тона). Мы предлагаем генерировать шаблоны "на лету" с использованием дифференцируемого Гауссова рендеринга физических кривых.

Каждый канал (класс сигнала) k задается макро-вектором $\vec{n}_k$ на гиперсфере S^n . Обучаемая нейросетевая функция $T : S^n \rightarrow \mathbb{R}^1 \rightarrow \mathbb{R}^2$ преобразует эту точку в набор параметров сплайна: кривую фундаментальной частоты $f_0(t)$ и амплитудные огибающие основного тона $A_1(t)$ и первого обертона $A_2(t)$. Шаблон W_k формируется аналитически для каждой точки матрицы (f_{idx}, t_{idx}) :

$$W_k(f_{idx}, t) = A_1(t) \exp\left(-\frac{(f_{idx} - f_0(t))^2}{2\sigma^2}\right) + A_2(t) \exp\left(-\frac{(f_{idx} - 2f_0(t))^2}{2\sigma^2}\right) \quad (1)$$

Такая архитектура жестко фиксирует физику распространения гармоник, делая обертон зависимым от $f_0(t)$, и кардинально сокращает размерность пространства поиска.

2.2 Микро-флуктуации в касательном пространстве

Для адаптации к естественной вариативности сигналов, форма шаблона не является абсолютно жесткой. В момент времени t сеть может предсказывать вектор микро-флуктуаций $\vec{v}_k(t) \in \mathbb{R}^{n+1}$. Для сохранения геометрии мы проецируем его на касательное пространство $T_p S^n$:

$$\vec{\Delta}_k(t) = \vec{v}_k(t) - (\vec{v}_k(t) \cdot \vec{n}_k) \vec{n}_k \quad (2)$$

Используя Экспоненциальное отображение (Retraction map), мы получаем смещенную точку на сфере: $\vec{n}_k(t) = \vec{n}_k \cos(\|\vec{\Delta}_k\|) + \frac{\vec{\Delta}_k}{\|\vec{\Delta}_k\|} \sin(\|\vec{\Delta}_k\|)$. Это позволяет библиотеке плавно экстраполировать многообразие сигналов, не разрушая базовую структуру класса.

2.3 Инстанс-сегментация секвенограмм и профиль эха

Сгенерированные шаблоны сворачиваются по времени с матрицей секвенограмм $H \in \mathbb{R}_{\geq 0}^{K \times T}$. Полученная «чистая» спектрограмма V подвергается реверберации через причинную частотно-зависимую 1D-свертку (Depthwise 1D Convolution) с матрицей эха $E \in \mathbb{R}^{F \times L_e}$, что запрещает нефизичный перенос энергии между частотными бинами.

3 Изотропная калибровка многозадачной оптимизации

Совместная оптимизация H , W и E требует наложения строгих структурных ограничений на H . Стандартное линейное суммирование штрафов ($\sum \alpha_i \mathcal{L}_i$) требует ручного подбора весов и нестабильно в разреженных пространствах. Мы предлагаем агрегировать компоненты ошибки через **Евклидову метрику**: $\mathcal{L}_{reg} = \sqrt{\sum \mathcal{L}_i^2}$. Однако это корректно только в том случае, если все штрафы находятся в изотропном пространстве. Мы достигаем этого через соблюдение принципа *Единичной локальной возвращающей силы*.

3.1 Структурные функционалы

Мы определяем три ключевых физических штрафа для секвенограмм:

1. **Бинаризация (Резкость):** $\mathcal{L}_{sharp} = \sum_t h(t)(1-h(t))$. Заставляет активации группироваться у 0 или 1.

2. **Локализация (Инстанс-сепарация):** Чтобы один канал не пытался описать два разнесенных во времени идентичных сигнала, мы штрафует временную дисперсию энергии в каждом канале относительно его центра масс μ_k : $\mathcal{L}_{loc} = \sum_k \sum_t h_k(t) \cdot (t - \mu_k)^2$. Это заставляет перекрывающиеся сигналы «разбегаться» по разным уровням k .
3. **Разреженность (Group Lasso):** $\mathcal{L}_{sparse} = \sum_k \max_t(h_k(t))$. Подавляет неиспользуемые каналы в абсолютный нуль.

Дополнительно вводится штраф на микро-флуктуации $\mathcal{L}_{dev} = \sum_t h(t) \|\vec{\Delta}(t)\|^2$, который требует стабильности формы только в моменты звучания сигнала ($h(t) > 0$), игнорируя фоновый вакуум.

3.2 Тригонометрия градиентов

Откалибровав каждый функционал $\mathcal{L}_i$ так, чтобы амплитуда его вариационной производной локально равнялась единице ($|\frac{\partial \mathcal{L}_i}{\partial h}|_{local} = 1$), мы можем рассмотреть полный градиент Евклидовой суммы. На примере двух штрафов:

$$\frac{\partial \mathcal{L}_{reg}}{\partial h_i} = \frac{\mathcal{L}_1}{\sqrt{\mathcal{L}_1^2 + \mathcal{L}_2^2}} \frac{\partial \mathcal{L}_1}{\partial h_i} + \frac{\mathcal{L}_2}{\sqrt{\mathcal{L}_1^2 + \mathcal{L}_2^2}} \frac{\partial \mathcal{L}_2}{\partial h_i} \quad (3)$$

Введя макроскопический угол состояния системы $\theta = \arctan(\mathcal{L}_2/\mathcal{L}_1)$, уравнение градиентного спуска принимает изящную тригонометрическую форму:

$$\frac{\partial \mathcal{L}_{reg}}{\partial h_i} = \underbrace{\cos(\theta)}_{\text{макро-вес}} \cdot \underbrace{\left(\frac{\partial \mathcal{L}_1}{\partial h_i}\right)}_{\text{микро-градиент}} + \underbrace{\sin(\theta)}_{\text{макро-вес}} \cdot \underbrace{\left(\frac{\partial \mathcal{L}_2}{\partial h_i}\right)}_{\text{микро-градиент}} \quad (4)$$

Это уравнение раскрывает двухуровневую систему **динамической маршрутизации градиентов**:

- **Макроскопический авто-баланс (Угол θ):** Если система успешно подавляет одну ошибку (например, $\mathcal{L}_1 \rightarrow 0$), угол $\theta \rightarrow \pi/2$. Тогда $\cos(\theta) \rightarrow 0$, а $\sin(\theta) \rightarrow 1$, и оптимизатор автоматически переключает 100% вычислительного внимания на оставшуюся проблему. В отличие от жестко заданных гиперпараметров, наша система *динамически вращает вектор градиента* в процессе обучения.
- **Микроскопический баланс:** Внутри скобок находятся откалиброванные локальные силы. Благодаря условию *единичной локальной силы*, в точках конфликта эти градиенты соизмеримы (амплитуды ≈ 1), что гарантирует, что ни один штраф не раздавит другой из-за разницы физических размерностей.

4 Стратегия совместного обучения

Поскольку процессы извлечения шаблона и подавления эха неотделимы друг от друга, модель обучается совместно из информированной начальной точки. Секвенограммы H инициализируются локальной RMS-огibaющей спектрограммы; профиль эха E — затухающими экспонентами с τ , убывающим с ростом частоты; а библиотека T — вертикальными широкополосными импульсами. В ходе оптимизации эхо забирает на себя дисперсионные хвосты сигнала, библиотека стягивается в идеальные гладкие параметрические кривые, а RMS-огibaющие коллапсируют в дельта-пики секвенограмм благодаря калиброванной Евклидовой метрике.

5 Результаты и обсуждение

Предложенная параметрическая модель кардинально решает проблему структурных искажений, свойственных классической слепой деконволюции. Внедрение дифференцируемого сплайн-рендеринга гарантирует физическую корректность обертонов, а штраф на дисперсию времени позволяет осуществлять инстанс-сегментацию перекрывающихся сигналов одного класса.

Самым значимым теоретическим вкладом работы является доказательство применимости Евклидовой оптимизации для многозадачных сетей при условии локальной градиентной калибровки. Переход от скалярных весов потерь к динамической фазовой тригонометрии ($\cos \theta$, $\sin \theta$) полностью устраняет необходимость в ручном подборе гиперпараметров, делая архитектуру самобалансирующейся.

6 Заключение

Платформа адаптивного извлечения секвенограмм представляет собой мощный дифференцируемый физический движок для акустического анализа. Объединяя геометрию римановых многообразий, физику акустики и теорию оптимизации, данный метод предлагает надежный, свободный от гиперпараметров инструмент для масштабного разбора сложных аудиосцен в условиях сильной реверберации.

Доступность данных и кода

Исходный код на Python/PyTorch (включая FFT-свертки и дифференцируемый рендерер) доступен в репозитории: <https://github.com/yourusername/AdaptiveSequenograms>.

Список литературы