

Адаптивное извлечение секвенограмм: совместная слепая деконволюция с помощью физически обоснованной параметрической ConvNMF и Евклидовой тригонометрии потерь

Ваше Имя*

Кафедра вычислительной обработки сигналов

18 апреля 2026 г.

Аннотация

Анализ акустических паттернов в естественных средах осложнен многолучевым распространением и перекрытием сигналов. Традиционные методы деконволюции страдают от проблемы «курицы и яйца» при попытке разделить неизвестный источник и неизвестное эхо. В данной работе представлена физически обоснованная генеративная архитектура для извлечения секвенограмм — разреженных векторов временной активации индивидуальных звуковых событий. Предложенный алгоритм выполняет совместную (joint) оптимизацию трех компонентов: причинного 1D-профиля эха, инстанс-специфичных секвенограмм и параметрического словаря шаблонов. Для моделирования словаря мы вводим дифференцируемый физический рендерер, где параметры частотной модуляции и гармоник (обертонов) задаются проекциями в касательном пространстве сферы ($T_p S^n$). Для обеспечения сходимости этой сложной многозадачной системы без использования эвристических гиперпараметров, мы представляем концепцию *Локальной калибровочной нормировки* и *Евклидовой тригонометрии градиентов*, которая динамически маршрутизирует вычислительные векторы оптимизатора. Метод демонстрирует исключительную точность при разделении спектрально идентичных, но сдвинутых по времени сигналов в условиях сильной реверберации.

1 Введение

Распознавание сигналов на частотно-временных представлениях (спектрограммах) в естественных условиях (леса, пещеры) сталкивается с фундаментальной физической проблемой: за первичной эмиссией следует реверберационный «хвост», размывающий акустическую энергию. При высокой плотности сигналов (например, эхолокация стаи летучих мышей) хвосты эха и последующие излучения сливаются в непрерывный спектральный шум.

Стандартные подходы (сверточные нейронные сети или классическая NMF) пытаются решить эту проблему, используя жесткие 2D-шаблоны. Однако такие методы обладают серьезными недостатками. Во-первых, они не способны разделить идентичные перекрывающиеся сигналы (instance segmentation). Во-вторых, обучение словаря паттернов на реальных данных неизбежно приводит к впитыванию реверберации в сам шаблон.

Для решения этих проблем мы предлагаем архитектуру параметрической слепой деконволюции. Метод одновременно извлекает адаптивное эхо среды, локализует звуковые объекты во времени (секвенограммы) и восстанавливает их безэховую спектральную структуру, используя физические законы распространения и генерации звука.

* Автор для корреспонденции: email@example.com

2 Материалы и методы

2.1 Генеративная модель совместной оптимизации

Пусть $S \in \mathbb{R}_{\geq 0}^{F \times T}$ — наблюдаемая спектрограмма. Мы моделируем ее как результат двух последовательных физических процессов: излучения и реверберации. Вектор-матрица активаций $H \in \mathbb{R}_{\geq 0}^{K \times T}$ (секвенограмма) описывает точное время звучания K независимых каналов. «Чистая» спектрограмма V формируется сверткой секвенограмм с адаптивными шаблонами W_k :

$$V(f, t) = \sum_{k=1}^K (H_k *_t W_k(f, \cdot))(t) \quad (1)$$

Затем V подвергается воздействию причинного частотно-зависимого 1D-фильтра эха $E \in \mathbb{R}_{\geq 0}^{F \times L_e}$:

$$\hat{S}(f, t) = (V(f, \cdot) *_t E(f, \cdot))(t) \quad (2)$$

Изоляция осей (свертка эха происходит строго вдоль оси времени) математически предотвращает нефизичный перенос энергии между частотами.

Поскольку H , W и E неизвестны, их оптимизация должна происходить совместно. В качестве инициализации алгоритма H задается как локальная огибающая энергии (RMS), E инициализируется как экспоненциальное затухание, а W генерируется дифференцируемым рендерером.

2.2 Физически обоснованный словарь: Дифференцируемый рендеринг и Касательное пространство

Вместо обучения «сырых» пикселей матрицы W_k , мы моделируем словарь как параметрическую физическую кривую. Базовая форма k -го канала задается макро-якорем на гиперсфере $\vec{n}_k \in S^n$. Для моделирования микро-флуктуаций (естественной вариативности формы сигнала во времени), нейросеть предсказывает вектор отклонений $\vec{v}_k(t)$, который проецируется на касательную плоскость:

$$\vec{\Delta}_k(t) = \vec{v}_k(t) - (\vec{v}_k(t) \cdot \vec{n}_k) \vec{n}_k \quad (3)$$

Экспоненциальное отображение возвращает точку обратно на сферу: $\vec{n}_k(t) = \text{Retract}(\vec{n}_k, \vec{\Delta}_k(t))$.

Вектор $\vec{n}_k(t)$ декодируется в параметры физического сплайна основной частоты $f_0(t)$ и независимые амплитудные огибающие $A_1(t)$, $A_2(t)$. Итоговый 2D-шаблон W_k генерируется с помощью оценки плотности (Gaussian Splatting):

$$W_k(f, \tau) = A_1(\tau) \exp\left(-\frac{(f - f_0(\tau))^2}{2\sigma^2}\right) + A_2(\tau) \exp\left(-\frac{(f - 2f_0(\tau))^2}{2\sigma^2}\right) \quad (4)$$

Данный подход обладает тремя фундаментальными преимуществами: 1) исключает появление артефактов (в отличие от сферических гармоник); 2) гарантирует жесткую физическую привязку первого обертона ($2f_0$); 3) позволяет оптимизировать гладкое латентное многообразие кривых.

2.3 Инстанс-сегментация: Локальная нормировка и Евклидова тригонометрия

Чтобы слепая деконволюция корректно разделяла перекрывающиеся сигналы, необходимо наложить структурные ограничения. Для извлечения секвенограмм мы формулируем три физических условия: бинаризацию ($\mathcal{L}_{\text{sharp}}$), временную локализацию (штраф дисперсии $\mathcal{L}_{\text{loc}}$, заставляющий каждый канал описывать строго один физический объект) и разреженность каналов ($\mathcal{L}_{\text{sparse}}$).

Традиционное многозадачное обучение объединяет штрафы линейно ($\sum \alpha_i \mathcal{L}_i$), что требует ручного подбора гиперпараметров и часто приводит к затуханию градиентов в разреженных сигналах. Мы предлагаем агрегировать компоненты с использованием **Евклидовой метрики** $\mathcal{L}_{\text{reg}} =$

$$\sqrt{\mathcal{L}_{\text{sharp}}^2 + \mathcal{L}_{\text{loc}}^2 + \mathcal{L}_{\text{sparse}}^2}.$$

Чтобы Евклидова норма была математически корректной, мы применяем принцип **Локальной калибровочной нормировки**. Мы отказываемся от глобального усреднения градиентов. Калибровка производится *интенсивно*: внутри зоны локального взаимодействия (вблизи $h(t) > 0$) амплитуда вариационной производной каждого функционала аналитически приводится к единице: $\left| \frac{\partial \mathcal{L}}{\partial h} \right|_{local} = 1$.

Это формирует изотропное пространство ошибок. Рассмотрим сигнал градиента для двумерного случая $\mathcal{L}_{reg} = \sqrt{\mathcal{L}_A^2 + \mathcal{L}_B^2}$. По правилу дифференцирования сложной функции:

$$\frac{\partial \mathcal{L}_{reg}}{\partial h_i} = \frac{\mathcal{L}_A}{\sqrt{\mathcal{L}_A^2 + \mathcal{L}_B^2}} \frac{\partial \mathcal{L}_A}{\partial h_i} + \frac{\mathcal{L}_B}{\sqrt{\mathcal{L}_A^2 + \mathcal{L}_B^2}} \frac{\partial \mathcal{L}_B}{\partial h_i} \quad (5)$$

Введя макроскопический угол состояния системы $\theta = \arctan(\mathcal{L}_B/\mathcal{L}_A)$, получаем уравнение градиентного спуска в тригонометрической форме:

$$\frac{\partial \mathcal{L}_{reg}}{\partial h_i} = \underbrace{\cos(\theta)}_{\text{глобальный вес}} \cdot \underbrace{\frac{\partial \mathcal{L}_A}{\partial h_i}}_{\text{откалиброванная сила}} + \underbrace{\sin(\theta)}_{\text{глобальный вес}} \cdot \underbrace{\frac{\partial \mathcal{L}_B}{\partial h_i}}_{\text{откалиброванная сила}} \quad (6)$$

Это уравнение раскрывает элегантную двухуровневую систему маршрутизации градиентов:

- **Микроскопический баланс:** В точках конфликта амплитуды локальных сил равны $|1|$. Фазовое пространство не искажается размерностями штрафов.
- **Макроскопический авто-баланс:** Вектор приоритетов не фиксирован гиперпараметрами, а динамически вращается. Если сеть минимизировала проблему A ($\cos(\theta) \rightarrow 0$), оптимизатор автоматически переключает 100% вычислительного внимания ($\sin(\theta) \rightarrow 1$) на проблему B .

3 Результаты

3.1 Синтетическая валидация (Разделение инстансов)

Для проверки концепции совместной оптимизации (Joint Optimization) был сгенерирован набор данных, содержащий перекрывающиеся спектрально идентичные вызовы (имитация стаи) с сильным частотно-зависимым эхом. Модель успешно избежала тривиальных решений. Благодаря штрафу дисперсии ($\mathcal{L}_{loc}$), идентичные, но разнесенные во времени сигналы были классифицированы в разные каналы H_k . Дифференцируемый рендерер точно восстановил независимые огибающие амплитуд основного тона и первого обертона, а модель эха E автоматически выявила высокие скорости затухания для высоких частот.

4 Обсуждение

Главным достижением предложенной архитектуры является физически обоснованное устранение проблемы «курицы и яйца» в задачах деконволюции. Жесткая параметризация библиотеки (сплайны и гармоники $2f_0$) в сочетании со штрафом микро-флуктуаций в касательном пространстве $T_p S^n$ не позволяет модели впитывать реверберацию в шаблон. Оставшаяся дисперсия акустической энергии математически вынуждена поглощаться 1D-матрицей эха E .

Кроме того, мы представили концепцию Евклидовой тригонометрии градиентов. Обеспечив единичную вариационную силу на локальном (микроскопическом) уровне, мы получили систему, которая самостоятельно вычисляет макроскопический угол атаки θ на каждом шаге оптимизации, полностью устраняя необходимость ручной балансировки многозадачных функций потерь.

5 Заключение

Представленный фреймворк параметрической ConvNMF предлагает строгий физический подход к анализу ревербирующих спектрограмм. Сочетание дифференцируемого гауссова рендеринга, проекций на сферу и масштабно-инвариантной евклидовой регуляризации превращает метод в вычислительно эффективный и полностью автономный инструмент для обнаружения паттернов, инстанс-сегментации и анализа среды в задачах крупномасштабного акустического мониторинга.

Доступность данных и кода

Исходный код (PyTorch), включая реализацию FFT-сверток, дифференцируемого рендеринга и калиброванных функций потерь, доступен в нашем репозитории: <https://github.com/yourusername/AdaptiveSequenograms>.

Список литературы